

DỰ ĐOÁN STRESS & HAPPINESS TỪ DỮ LIỆU HÀNH VI INSTAGRÂM

Nhóm :

- Nguyễn Minh Toàn - B23DCCN832
- Phan Văn Hoàng Việt - B23DCCN922
- Nguyễn Thị Yến Vy - B23DCCN952



DỰ ĐOÁN STRESS & HAPPINESS TỪ DỮ LIỆU HÀNH VI INSTAGRAM

Báo cáo môn Trí tuệ nhân tạo • Phân tích mô hình hồi quy, feature engineering và persona clustering

Dataset

1.547.896 dòng gốc
400.000 dòng train mẫu

2 bài toán hồi quy

perceived_stress_score
self_reported_happiness

Hướng nghiên cứu

Dự đoán điểm số + phân nhóm
hành vi người dùng

1. Bối cảnh nghiên cứu

Bài toán liên hệ giữa hành vi sử dụng mạng xã hội và chỉ số sức khỏe tinh thần tự báo cáo

Vấn đề đặt ra

Instagram tạo ra nhiều dấu vết hành vi: thời lượng sử dụng, số phiên, tương tác, nội dung xem, nhịp ngủ, vận động và thông tin lối sống. Câu hỏi học thuật là liệu các tín hiệu này có đủ để ước lượng mức stress và happiness hay không.

Bản chất bài toán

Đây không phải bài toán phân loại nhãn rời rạc mà là hồi quy: mô hình dự đoán một giá trị số liên tục/giả liên tục. Stress có thang 0–40; happiness có thang 1–10.

Ý nghĩa báo cáo

Không chỉ trình bày code chạy được, báo cáo cần giải thích pipeline khoa học: dữ liệu → tiền xử lý → đặc trưng → mô hình → đánh giá → giới hạn → hướng cải thiện.

2. Mục tiêu nghiên cứu và câu hỏi chính

Mục tiêu 1 — Dự đoán stress

Xây dựng mô hình hồi quy dự đoán `perceived_stress_score` từ các biến nhân khẩu học, sức khỏe, lối sống và hành vi sử dụng Instagram.

Mục tiêu 2 — Dự đoán happiness

Dự đoán `self_reported_happiness` và kiểm tra liệu stress dự đoán có hỗ trợ mô hình happiness hay không.

Mục tiêu 3 — Giải thích mô hình

So sánh mô hình với baseline, đọc chỉ số MAE/RMSE/R² và phân tích tầm quan trọng của đặc trưng.

Mục tiêu 4 — Phân nhóm persona

Dùng KMeans để tìm nhóm hành vi: ví dụ nhóm sử dụng thấp/ngủ tốt/stress thấp và nhóm sử dụng cao/ngủ thấp/stress cao.

- RQ1: Các tín hiệu hành vi có dự đoán stress tốt hơn trung bình đơn giản không?
- RQ2: Happiness có dễ dự đoán như stress không? Nếu không, nguyên nhân học thuật là gì?
- RQ3: Có thể rút ra nhóm hành vi người dùng có ý nghĩa diễn giải không?

3. Tổng quan dữ liệu

Notebook dùng `instagram_users_lifestyle.csv` với 58 cột ban đầu

Thuộc tính	Giá trị trong notebook
Số dòng gốc	1.547.896
Số dòng sau lấy mẫu	400.000
Số cột ban đầu	58
Số cột sau feature engineering	100
Train/Test split	80% / 20% = 320.000 / 80.000
Random seed	42

Các nhóm biến đầu vào

Nhân khẩu học, lối sống, sức khỏe, thời lượng sử dụng Instagram, tương tác, mạng lưới follow/follower, phản hồi thông báo, quảng cáo, ngày đăng nhập.

Hai biến mục tiêu

Stress: `perceived_stress_score`, thang 0–40.
Happiness: `self_reported_happiness`, thang 1–10.

Lưu ý học thuật

Lấy mẫu 400.000 dòng giúp giảm chi phí tính toán nhưng vẫn đủ lớn để đánh giá ổn định hơn so với mẫu nhỏ.

4. Biến mục tiêu và phân phối mô tả

Thống kê	Stress 0–40	Happiness 1–10
count	400.000	400.000
mean	19,97	5,50
std	11,84	2,87
min	0	1
median	20	6
max	40	10

Diễn giải stress

Mean $\approx$ 20 trên thang 0–40, độ lệch chuẩn lớn $\approx$ 11,84. Biến stress có biên độ rộng nên mô hình có nhiều phương sai để giải thích.


Diễn giải happiness

Mean $\approx$ 5,5 trên thang 1–10. Đây là biến chủ quan, dễ chịu nhiều bởi yếu tố ngoài dữ liệu như tính cách, sự kiện đời sống, môi trường xã hội.

Kỳ vọng mô hình

Stress có thể dự đoán tốt hơn vì liên hệ trực tiếp hơn với thời lượng sử dụng, ngủ, vận động, công việc. Happiness thường khó vì bản chất đa nhân tố.

5. Kiến trúc pipeline tổng thể



Điểm mạnh của pipeline

Sử dụng Pipeline + ColumnTransformer giúp tiền xử lý và mô hình được đóng gói thống nhất, giảm lỗi khi dự đoán dữ liệu mới.

Điểm học thuật quan trọng

Happiness dùng stress_pred_feature tạo bằng out-of-fold prediction, tránh dùng stress thật gây target leakage.

Kết quả cuối

Lưu stress_pipeline, happiness_pipeline, persona_preprocess, persona_model và metadata để tái sử dụng.

6. Tiền xử lý dữ liệu

Các bước làm sạch giúp dữ liệu phù hợp với mô hình học máy

- Chuẩn hóa tên cột: chuyển về chữ thường, bỏ ký tự đặc biệt, thay khoảng trắng bằng dấu gạch dưới.
- Loại bản ghi trùng lặp toàn dòng và trùng user_id để giảm sai lệch do người dùng xuất hiện nhiều lần.
- Ép kiểu số cho các cột object nếu tỷ lệ chuyển đổi hợp lệ $\geq 90\%$.
- Chuyển last_login_date thành year, month, dayofweek, is_weekend và days_since_last_login.
- Thay inf/-inf bằng NaN để pipeline xử lý bằng imputer.

Imputation

Biến số: SimpleImputer(strategy='median').

Biến phân loại: SimpleImputer(strategy='most_frequent').

Encoding

Biến phân loại được mã hóa bằng OrdinalEncoder với unknown_value = -1 để xử lý giá trị mới khi test/predict.

Outlier handling

Một số cột đếm/thời lượng được clip theo percentile 1%–99% để giảm ảnh hưởng của giá trị cực đoan.

7. Feature Engineering: chuyển dữ liệu thô thành tín hiệu học được

Cường độ sử dụng

$\text{usage_intensity} = \text{daily_active_minutes} \times \text{sessions_per_day} \times \text{minutes_per_session}$

Tương tác xã hội

total_interactions, daily_dm_total, dm_sent_received_ratio

Thời gian bề mặt

total_surface_time và tỷ lệ feed/explore/messages/reels

Sức khỏe – lối sống

sleep_distance_from_8h, sleep_under_6h, work_sleep_ratio, usage_sleep_ratio

Mạng lưới

follower_following_ratio, network_size, log transforms

Tương tác chéo

sleep_x_exercise, usage_x_social_events, usage_x_bad_sleep

8. Kiểm soát leakage và thiết kế đặc trưng công bằng

Loại định danh

Bỏ user_id, id, name, username, email, phone, address, profile_url, url/link và các cột kết thúc _id.

Loại target khỏi feature

Khi train stress: bỏ mọi cột chứa stress/happiness.
Khi train happiness: không dùng stress thật.

Bỏ cột kém hữu ích

app_name bị loại vì hầu như chỉ là Instagram; object có quá nhiều giá trị cũng bị loại.

Tại sao leakage nguy hiểm?

- Leakage xảy ra khi mô hình nhìn thấy thông tin mà khi triển khai thật không có.
- Kết quả validation/test có thể rất cao giả tạo nhưng mô hình không tổng quát hóa.
- Trong dự án này, stress_pred_feature chỉ được tạo từ dự đoán OOF, không dùng stress thật để dự đoán happiness.

Thiết kế đúng cho happiness

Train stress model → tạo dự đoán stress ngoài fold cho train set → thêm vào X_happiness → train happiness. Cách này mô phỏng tình huống triển khai: chỉ có thể dùng stress dự đoán, không có nhãn stress thật.

9. Các mô hình được so sánh

Mô hình	Vai trò	Ưu điểm chính
DummyRegressor	Baseline	Dự đoán trung bình, dùng làm mốc tối thiểu
HistGradientBoosting	Ứng viên chính	Boosting cây quyết định, học quan hệ phi tuyến, early stopping
LightGBM	Ứng viên chính	Gradient boosting hiệu quả trên dữ liệu bảng lớn
RandomForest	So sánh ensemble	Giảm phương sai bằng nhiều cây độc lập, dễ giải thích tương đối

Tư duy học thuật

Không nên chỉ báo cáo model tốt nhất; cần có baseline để chứng minh mô hình học được tín hiệu thật.

Tư duy thực nghiệm

So sánh nhiều mô hình giúp hạn chế kết luận phụ thuộc vào một thuật toán duy nhất.

Tư duy triển khai

Pipeline lưu bằng joblib nên có thể tái sử dụng khi nhận dữ liệu người dùng mới.

10. Thước đo đánh giá mô hình hồi quy

MAE - Mean Absolute Error

Sai số tuyệt đối trung bình.
Dễ hiểu theo đơn vị gốc của target.

Càng nhỏ càng tốt.
Ví dụ: stress MAE $\approx 4,88$ nghĩa là sai trung bình khoảng 4,88 điểm trên thang 0–40.

RMSE - Root Mean Squared Error

Phạt mạnh các lỗi lớn vì bình phương sai số trước khi lấy căn.

Càng nhỏ càng tốt.
Nếu RMSE cao hơn MAE nhiều, có thể có một số dự đoán sai lớn.

R² - Coefficient of Determination

Tỷ lệ phương sai của target được mô hình giải thích.

R² = 0: tương đương dự đoán trung bình.
R² càng gần 1 càng tốt.

Công thức

$$\text{MAE} = \text{mean}(|y - \hat{y}|) \quad \bullet \quad \text{RMSE} = \sqrt{\text{mean}((y - \hat{y})^2)} \quad \bullet \quad R^2 = 1 - \text{SS}_{\text{res}} / \text{SS}_{\text{tot}}$$

11. Chiến lược chia dữ liệu và validation

Train/Test split


Dữ liệu sau feature engineering được chia 80/20. Test set 80.000 dòng chỉ dùng để báo cáo kết quả cuối.

Validation nội bộ

Trong train set, tiếp tục chia 80/20 để chọn model tốt nhất theo MAE.

OOF prediction


KFold 5 folds tạo stress_pred_feature cho happiness, tránh leakage.



- Việc chọn mô hình trên validation rồi đánh giá lại trên test giúp giảm thiên lệch do chọn model.
- OOF giúp biến dự đoán stress trong train giống điều kiện triển khai thực tế.
- Random seed cố định giúp kết quả tái lập trong báo cáo.

12. Kết quả mô hình Stress

Mô hình validation	MAE	RMSE	R ²
Baseline	10,2523	11,8334	≈ 0
HistGradientBoosting	4,8868	6,0964	0,7346
LightGBM	4,8875	6,1018	0,7341
RandomForest	4,9290	6,1395	0,7308
TEST: HistGradientBoosting	4,8829	6,0960	0,7351



Nhận xét học thuật


Stress đạt $R^2 \approx 0,735$, tức mô hình giải thích được khoảng 73,5% phương sai trên tập test. So với baseline, MAE giảm từ khoảng 10,25 xuống 4,88.

Kết luận tạm thời

Các đặc trưng hành vi/lối sống trong dataset có tín hiệu mạnh đối với stress; mô hình học được quan hệ phi tuyến ổn định.

13. Kết quả mô hình Happiness

Mô hình validation	MAE	RMSE	R ²
Baseline	2,4926	2,8668	≈ 0
HistGradientBoosting	2,2206	2,6235	0,1625
LightGBM	2,2203	2,6262	0,1608
RandomForest	2,2229	2,6290	0,1590
TEST: LightGBM	2,2200	2,6239	0,1663





Nhận xét học thuật

Happiness có cải thiện so với baseline nhưng R^2 chỉ $\approx 0,166$. Nghĩa là mô hình chỉ giải thích được khoảng 16,6% phương sai của happiness.

Cách diễn giải đúng

Kết quả không phải code sai; nó cho thấy biến happiness khó dự đoán hơn vì mang tính chủ quan và chịu ảnh hưởng của nhiều yếu tố không có trong dữ liệu.

14. So sánh hai bài toán: Stress dễ học hơn Happiness



Stress

R^2 cao, MAE giảm mạnh so với baseline.
Tín hiệu đầu vào liên quan rõ với stress: ngủ, cường độ sử dụng, workload, tương tác.

Happiness

R^2 thấp, chỉ cải thiện nhẹ so với baseline.
Happiness là chỉ số tổng hợp, khó đo bằng hành vi Instagram đơn lẻ.

Bài học

Đánh giá ML cần dựa vào bản chất target, không chỉ cố tăng thuật toán.
Dữ liệu quyết định trần hiệu năng.

15. Vì sao mô hình Happiness thấp?

1. Tính chủ quan cao

Happiness tự báo cáo phụ thuộc tâm trạng tức thời, tính cách, gia đình, tài chính, quan hệ xã hội, sự kiện đời sống — nhiều yếu tố không có trong dataset.

2. Nhiều đo lường target

Nếu nhận happiness được trả lời không ổn định hoặc theo cảm nhận cá nhân, mô hình khó học vì cùng đặc trưng có thể cho nhiều mức happiness khác nhau.

3. Quan hệ phi tuyến/gián tiếp

Instagram có thể ảnh hưởng gián tiếp qua stress, giấc ngủ, quan hệ xã hội. Một mô hình bảng có thể chưa nắm hết quan hệ phức tạp.

4. Thiếu biến nền quan trọng

Không có các biến tâm lý đã chuẩn hóa như SWLS, PANAS, Big Five, hỗ trợ xã hội, biến cố gần đây, chất lượng quan hệ.


5. Regression-to-mean

Với target khó và nhiều, mô hình có xu hướng dự đoán gần trung bình, làm MAE vừa phải nhưng R^2 thấp.

6. Cần dữ liệu thời gian

Happiness có thể thay đổi theo ngày/tuần. Dữ liệu dạng snapshot khó mô tả động lực thời gian.

16. Phân tích đặc trưng quan trọng cho Happiness



Đặc trưng nổi bật nhất

stress_pred_feature có importance cao nhất. Điều này phù hợp trực giác: stress dự đoán là tín hiệu trung gian mạnh cho happiness.

Nhóm đặc trưng đáng chú ý

body_mass_index, follower_following_ratio, days_since_last_login, offline_social_lifestyle_score, tỷ lệ thời gian trên feed/explore/messages.

Lưu ý diễn giải

Feature importance của cây cho biết biến được mô hình dùng nhiều; không đồng nghĩa biến đó là nguyên nhân gây happiness.

17. Vai trò của stress_pred_feature trong mô hình Happiness

Bước 1

Train mô hình stress từ các đặc trưng không chứa nhãn stress/happiness.

Bước 2

Dùng KFold 5 folds để tạo dự đoán stress OOF cho từng dòng train.

Bước 3

Thêm stress_pred_feature vào bộ đặc trưng happiness và train LightGBM.



Vì sao không dùng stress thật?

- Trong thực tế, khi dự đoán một user mới, ta không biết nhãn stress thật.
- Dùng stress thật để train happiness sẽ làm kết quả ảo vì target đã bị rò rỉ.
- OOF prediction giúp stress_pred_feature có bản chất giống dự đoán triển khai, công bằng hơn.

Ý nghĩa mô hình hóa

Đây là dạng stacking đơn giản: mô hình tầng 1 dự đoán stress, đầu ra được đưa sang mô hình tầng 2 dự đoán happiness. Cách này hợp lý khi stress là biến trung gian có quan hệ với happiness.

18. Persona Clustering bằng KMeans



Persona	Instagram/day	Sessions/day	Stress	Happiness
0: Low Usage - Good Sleep - Active - Low Stress	100,79	5,29	11,70	6,22
1: High Usage - Low Sleep - Less Active - High Stress	283,87	15,90	29,11	4,72

19. Diễn giải học thuật của persona

Persona 0: Low Usage - Good Sleep - Active - Low Stress

Nhóm này có `daily_active_minutes` $\approx 100,8$; `sessions/day` $\approx 5,29$; `stress` thật $\approx 11,70$; `happiness` thật $\approx 6,22$. Đây là nhóm có mức sử dụng thấp hơn và trạng thái tinh thần tích cực hơn trong dữ liệu.

Persona 1: High Usage - Low Sleep - Less Active - High Stress

Nhóm này có `daily_active_minutes` $\approx 283,9$; `sessions/day` $\approx 15,90$; `stress` thật $\approx 29,11$; `happiness` thật $\approx 4,72$. Nhóm này thể hiện cường độ dùng Instagram cao và stress cao hơn.

Silhouette k=2

Best $k = 2$ với `silhouette` $\approx 0,248$. Mức này không quá cao, nghĩa là cụm có ý nghĩa nhưng chưa tách biệt rất mạnh.

Ý nghĩa ứng dụng

Persona giúp trình bày kết quả dễ hiểu hơn mô hình hồi quy thuần: người nghe thấy được nhóm hành vi cụ thể.

Giới hạn

KMeans giả định cụm hình cầu trong không gian chuẩn hóa; không đảm bảo phản ánh nhóm xã hội thật.

20. Đóng gói mô hình và luồng dự đoán dữ liệu mới

File được lưu


stress_pipeline.joblib
happiness_pipeline.joblib
persona_preprocess.joblib
persona_model.joblib
metadata.json

Metadata

Lưu danh sách features, target, best model, metrics, persona names, cột bị loại và cấu hình tạo model.

Self-test predict

Hàm predict_from_raw_dataframe chuẩn hóa raw input, tạo feature, align cột, dự đoán stress, happiness, persona.



21. Ví dụ đầu ra dự đoán

User mẫu	Stress pred	Happiness pred	Persona
0	35,68	2,87	High Usage - Low Sleep - High Stress
1	12,53	5,86	Low Usage - Good Sleep - Low Stress
2	22,69	5,34	Low Usage - Good Sleep - Low Stress
3	33,18	4,17	High Usage - Low Sleep - High Stress
4	5,99	7,19	Low Usage - Good Sleep - Low Stress

Cách đọc kết quả

Mỗi user mới được gán đồng thời ba đầu ra: điểm stress dự đoán, điểm happiness dự đoán và persona hành vi.

Lưu ý sai số

Một số mẫu có dự đoán happiness lệch khá xa thực tế. Đây là minh chứng trực quan cho giới hạn của bài toán happiness.

22. Giới hạn nghiên cứu

Giới hạn về dữ liệu

Dữ liệu dạng bảng snapshot nên thiếu diễn biến theo thời gian. Một số yếu tố quan trọng của sức khỏe tinh thần không được quan sát.

Giới hạn về nhân

Stress và happiness tự báo cáo có thể nhiễu, lệch theo văn hóa, ngữ cảnh, tâm trạng lúc trả lời.

Giới hạn về diễn giải

Feature importance không phải causal effect. Không thể kết luận Instagram gây stress/happiness từ mô hình hồi quy này.

Giới hạn thuật toán

HistGB/LightGBM/RF tốt cho dữ liệu bảng nhưng chưa mô hình hóa được chuỗi thời gian hay quan hệ nhân quả.

Giới hạn đánh giá

Chưa có cross-validation toàn bộ pipeline cho báo cáo cuối, chưa có confidence interval cho metrics.

Giới hạn cụm persona

Silhouette khoảng 0,248 cho thấy cụm có tính diễn giải nhưng độ tách chưa mạnh.

23. Hướng cải thiện

- Thu thập thêm biến tâm lý chuẩn hóa: thang PSS cho stress, SWLS/PANAS cho happiness, Big Five, social support.
- Dữ liệu theo thời gian: daily/weekly logs để mô hình hóa xu hướng, độ trễ, thay đổi trước/sau khi dùng Instagram.
- Thêm phương pháp giải thích: permutation importance, SHAP, partial dependence để hiểu tác động phi tuyến.
- Tối ưu mô hình: Optuna/GridSearch, monotonic constraints nếu có giả thuyết, ensemble/stacking cẩn thận hơn.
- Đánh giá chắc chắn hơn: k-fold cross-validation toàn pipeline, confidence interval cho MAE/RMSE/ R^2 , kiểm tra lỗi theo từng nhóm người dùng.
- Chuyển từ dự đoán sang nghiên cứu nhân quả: cần thiết kế thực nghiệm hoặc quasi-experiment nếu muốn kết luận nguyên nhân.

24. Kết luận chính

Kết luận 1

Mô hình stress hoạt động tốt: HistGradientBoosting đạt MAE $\approx 4,88$ và $R^2 \approx 0,735$ trên tập test.

Kết luận 2

Mô hình happiness có cải thiện so với baseline nhưng $R^2 \approx 0,166$, phản ánh bản chất khó dự đoán của chỉ số chủ quan.

Kết luận 3

stress_pred_feature là biến quan trọng nhất cho happiness nhưng phải dùng OOF để tránh leakage.

Kết luận 4

Persona clustering tìm được 2 nhóm có diễn giải: low usage/low stress và high usage/high stress.


Kết luận 5

Dự án có pipeline triển khai: preprocess, predict stress, predict happiness, predict persona và lưu metadata.


Thông điệp cuối

Kết quả cần được hiểu như dự đoán thống kê, mang tính học thuật không mang tính áp đặt.

25. Demo thực tế



25. Demo thực tế



25. Demo thực tế

Social Media Well-being Predictor

Phân tích sức khỏe tinh thần từ thói quen sử dụng mạng xã hội

Nhập thông tin của bạn

Vui lòng điền đầy đủ thông tin để nhận được phân tích chính xác nhất

Thông tin cá nhân

Tuổi *	Giới tính *	Quốc gia *
25	Nam	Vietnam
Khu vực *	Mức thu nhập *	Tình trạng việc làm *
Thành thị	Trung bình	Toàn thời gian
Trình độ học vấn *	Tình trạng hôn nhân *	Có con? *
Đại học	Độc thân	Không

25. Demo thực tế


Chỉ số sức khỏe

Giờ ngủ/đêm *	Giờ tập/tuần *	Số bước/ngày *
7	3	5000
Chất lượng chế độ ăn *	Hút thuốc? *	Tần suất uống rượu *
Trung bình	Không	Hiếm khi
BMI (Chỉ số khối cơ thể) *		
22.5		

25. Demo thực tế

[illegible]

26. Kết quả



27. Phân tích lại theo gợi ý cải thiện

 **Gợi ý cải thiện**

Thử tìm thêm các hoạt động mới để nâng cao tinh thần

Hãy duy trì và cải thiện lối sống hiện tại

Phát hiện căng thẳng cao. Hãy thử thiền định hoặc các bài tập chánh niệm

Đảm bảo bạn ngủ đủ giấc (7-9 tiếng mỗi đêm)

Thói quen sử dụng mạng xã hội ở mức trung bình. Hãy chú ý không tăng thêm

Phân tích lại


28. Lịch sử

Predictions Gần Đây


Người Dùng	Thời Gian	Hạnh Phúc	Căng Thẳng	Persona
user5_demo	17:07:29 24/4/2026	5.81	7.7	Moderate User
user10_demo	15:30:24 24/4/2026	5.81	7.7	Moderate User
user4_demo	15:19:34 24/4/2026	6.28	4.56	Moderate User
user3_demo	15:18:34 24/4/2026	6.05	6.16	Moderate User
user6_demo	15:13:34 24/4/2026	8.42	2.44	Light User
user8_demo	14:57:34 24/4/2026	8.74	2.23	Light User
user5_demo	14:44:34 24/4/2026	5.42	5.34	Moderate User
user10_demo	14:43:34 24/4/2026	5.77	5.99	Moderate User
user1_demo	14:17:34 24/4/2026	5.37	8.88	Doom-Scroller
user2_demo	13:48:34 24/4/2026	3.16	8.4	Doom-Scroller

29. Thống kê

 **Phân Bố Persona**



30. Admin



Phụ lục A. Cấu hình thực nghiệm trong notebook

Thành phần	Cấu hình
MAX_ROWS	400_000
RUN_RANDOM_FOREST	True
OOF_FOLDS	5
USE_STRESS_PRED_FEATURE	True
Stress clip range	0–40
Happiness clip range	1–10
Best stress model	HistGradientBoosting
Best happiness model	LightGBM

Tính tái lập

RANDOM_SEED = 42 được dùng cho numpy, train_test_split, KFold, RandomForest, KMeans và các mô hình liên quan.

Tính triển khai

metadata.json lưu danh sách cột kỳ vọng để align dữ liệu mới, tránh lỗi thiếu/thừa cột khi dự đoán.

Tính mở rộng

Có thể thay LightGBM/HistGB bằng mô hình khác mà vẫn giữ nguyên khung preprocessing và đánh giá.